

Tasca S3.01. Introducció a BigQuery i SQL al Núvol

Descripció

Benvingut al núvol. En aquest sprint, faràs el salt de treballar en local (MySQL) a treballar amb **Google BigQuery**, un Data Warehouse serverless dissenyat per a l'anàlisi de dades a gran escala.

En l'entorn empresarial actual, l'analista no acostuma a crear bases de dades des de zero, sinó que ha de connectar-se a repositoris existents (Data Lakes), comprendre els costos del núvol i preparar les dades brutes per a l'anàlisi (ELT).

⚠ Important

- » **Control de Costos:** A BigQuery, cada consulta costa diners. Abans d'executar res, fixa't sempre en el missatge del validador ("Dry Run") a dalt a la dreta.
- » **Ubicació de les Dades:** Assegura't que el teu Dataset estigui a la regió EU (Multiple regions) o les connexions fallaran.

Limitacions del Sandbox

La zona de proves de BigQuery (Sandbox) està subjecta als següents límits:

- » S'apliquen tots els límits i quotes habituals de BigQuery.
- » Tens 10 GB d'emmagatzematge actiu i 1 TB de dades de consulta processades cada mes sense cap cost.
- » ⚠ **Caducitat:** Totes les taules, vistes i particions caduquen de forma automàtica després de **60 dies**.
- » No admet funcions avançades com: Transmissió de dades (Streaming), DML (UPDATE/DELETE massius) o el Servei de transferència de dades.

Nivell 1: Entorn i Ingesta Híbrida (Code-First)

Escenari:

Acabeu d'arribar a l'empresa. L'equip d'Enginyeria de Dades ha deixat els fitxers històrics al Data Lake corporatiu.

La teva primera missió és dissenyar i crear l'entorn de treball. El CTO exigeix professionalitat: no bolcarem dades sense ordre, sinó que implementarem una Arquitectura Medallion.

Exercici 1: Arquitectura de Dades (Lògica vs. Física)

Abans de tocar la consola, has d'entendre la diferència entre allò que dissenyem i allò que construïm:

- » **Arquitectura Lògica (Capes de Dades):** És el disseny conceptual. Organitza les dades segons el seu nivell de qualitat (Bronze, Silver, Gold).
- » **Implementació Física (Datasets):** És el recurs real a Google Cloud. A BigQuery, utilitzarem Datasets (contenidors) per materialitzar físicament aquestes capes lògiques.

✖ Tasques:


Implementareu físicament l'arquitectura lògica creant tres Datasets dins d'un mateix projecte per centralitzar la facturació i els permisos.

👉 Crea un **Nou Projecte** a Google Cloud anomenat:

sprint3-analytics-[el-teu-nom].

Ho pots crear per la UI, però si ho fas per Consola (gcloud CLI) té un plus.

Para crear el proyecto, opté por utilizar la consola mediante gcloud CLI, ya que ya había utilizado Bash anteriormente, aunque tuve que investigar cómo utilizarlo correctamente en Cloud Shell. Una vez creado el proyecto, configuré sprint3-analytics-gabriella como proyecto activo mediante gcloud config set project, para que los siguientes comandos de gcloud se ejecutaran sobre este proyecto.



The screenshot shows the Google Cloud Shell interface. At the top, it says 'Olá, Gabriella N. Alves'. Below that, it prompts the user to 'Crie ou selecione um projeto para começar a usar o Google Cloud' with a link to 'Saiba mais sobre projetos'. A button 'Criar ou selecionar um projeto' is visible. Below that, there's a section for 'Teste o chat do Gemini Cloud Assist'. The bottom part of the image shows a terminal window with the following commands and output:


```
gabi_naives@cloudshell:~$ gcloud projects create sprint3-analytics-gabriella
Create in progress for [https://cloudresourcemanager.googleapis.com/v1/projects/sprint3-analytics-gabriella].
Waiting for [operations/create_project.global.7000540923259239988] to finish...done.
Enabling service [cloudapis.googleapis.com] on project [sprint3-analytics-gabriella]...
Operation "operations/enableService.global.42396940160-71be748-5cf5-4cca-9fdd-9bce235ea38e" finished successfully.
gabi_naives@cloudshell:~$ gcloud config set project sprint3-analytics-gabriella
Updated property [core/project].
gabi_naives@cloudshell:~ (sprint3-analytics-gabriella)$
```

Per demostrar el teu domini total de la plataforma, crearàs cadascun dels datasets utilitzant un mètode diferent:


- » **Dataset Físic** sprint3_bronze → Capa Lògica Bronze (Dades Crudes)
 - Funció: Dades crues tal com arriben de la font.

- Método: Utiliza la **Interfície Gráfica (UI)** de BigQuery (fent clics).


El dataset sprint3_bronze fue creado mediante la interfaz gráfica (UI) de BigQuery, tal como se solicitaba en el ejercicio. Una vez creado el proyecto, accedimos a BigQuery y seleccionamos la opción para crear un nuevo conjunto de datos.



Creamos el dataset sprint3_bronze y configuramos su ubicación en EU (varias regiones de la Unión Europea), tal como requiere el ejercicio.




El dataset fue creado correctamente y representa físicamente la capa lógica Bronze, destinada a almacenar los datos crudos tal como llegan de la fuente.




- » **Dataset Físic sprint3_silver** → Capa Lógica Silver (Dades Netes)
 - Funció: Dades netes, tipades i deduplicades.
 - Mètode: Utilitza codi SQL (CREATE SCHEMA).

Para crear el conjunto de datos Silver mediante SQL, fue necesario crear una consulta utilizando la función CREATE SCHEMA. Además, se especificó la ubicación EU para mantener todos los conjuntos de datos en la misma región. El dataset fue creado correctamente y representa físicamente la capa lógica Silver, destinada a almacenar datos limpios, tipados y deduplicados.



- » **Dataset Físic** sprint3_gold → Capa Lògica Gold (Dades de Negoci)
 - Funció: Dades agregades llestes per a informes i panells de control (dashboards).
 - Mètode: Utilitza Cloud Shell (Línia d'ordres bq).

El dataset sprint3_gold fue creado mediante Cloud Shell, tal como se solicitaba en el ejercicio. Se utilizó el parámetro --location=EU para mantener la misma ubicación física que los datasets Bronze y Silver. El dataset fue creado correctamente y representa físicamente la capa lógica Gold, destinada a almacenar datos agregados y preparados para informes y dashboards.



```

Welcome to Cloud Shell! Type "help" to get started.
Your Cloud Platform project in this session is set to sprint3-analytics-gabriella.
Use 'gcloud config set project [PROJECT ID]' to change to a different project.
gabi_nalves@cloudshell:~ (sprint3-analytics-gabriella) $ bq --location=EU mk \
--dataset \
sprint3_gold
Dataset 'sprint3-analytics-gabriella:sprint3_gold' successfully created.
gabi_nalves@cloudshell:~ (sprint3-analytics-gabriella) $

```

Tingueu en compte la ubicació de les dades originals per decidir la ubicació física dels tres Datasets.

📌 **Nota:** Encara que siguin capes lògiques diferents, físicament han de viure a la mateixa regió per poder "parlar" entre elles sense costos de transferència.

Exercici 2: Ingesta en Capa Bronze (Connexió DDL)

Un analista professional automatitza les tasques. Ara que tens la teva arquitectura a punt, poblarem la primera capa (**Bronze**) sense moure les dades originals, creant **Taules Externes** que apuntin al Data Lake.

✿ Tasca:


Escriu i executa les sentències CREATE EXTERNAL TABLE per connectar els següents fitxers al *dataset* **sprint3_bronze**. Para molta atenció a les "Notes Tècniques", ja que no tots els arxius tenen el mateix format.

Taula	Domini	Ruta al Núvol (URI)	Notes Tècniques
transactions_raw	ERP	gs://bootcamp-data-analytics-public/ERP/transactions.csv	Delimitador : ; (Punt i coma)
companies_raw	ERP	gs://bootcamp-data-analytics-public/ERP/companies.csv	Capçalera: Ignora la 1a fila. Defineix l'esquema manualment perquè tot és text.
american_users_raw	CRM	gs://bootcamp-data-analytics-public/CRM/american_users.csv	Estàndard.
european_users_raw	CRM	gs://bootcamp-data-analytics-public/CRM/european_users.csv	Estàndard.
credit_cards_raw	CRM	gs://bootcamp-data-analytics-public/CRM/credit_cards.csv	Estàndard.

👉 Entrega:

El codi SQL utilitzat per a transactions_raw i una captura de pantalla amb les 5 taules creades.

Creación de transactions_raw:



Para crear la tabla se utilizé `CREATE EXTERNAL TABLE IF NOT EXISTS` dentro del dataset `sprint3_bronze`. La tabla apunta al archivo `transactions.csv` almacenado en Cloud. Se configuró `field_delimiter = ';' ,` ya que los campos están separados por punto y coma. La consulta se ejecutó correctamente y la tabla externa fue creada en BigQuery.

```
CREATE EXTERNAL TABLE IF NOT EXISTS `sprint3-analytics-  
gabriella.sprint3-bronze.transactions_raw`
```

```
OPTIONS (
```


```
  format='csv',
```

```
  uris=['gs://bootcamp-data-analytics-public/ERP/transactions.csv'],
```

```
  field_delimiter = ';' ,
```

```
);
```

Creación de companies_raw:



Para crear la tabla companies_raw el proceso fue un poco distinto, ya que era necesario conocer los nombres de las columnas (lo que hice a través del Shell para consultar la primera línea del archivo csv).

En este caso, inserimos manualmente las columnas, todas de tipo string, y especificamos que se ignorara la primera fila del archivo, ya que corresponde a la cabecera.

```
CREATE EXTERNAL TABLE IF NOT EXISTS `sprint3-analytics-gabriella.sprint3_bronze.companies_raw`
```

```
(company_id STRING,
```

```
company_name STRING,
```

```
phone STRING,
```

```
email STRING,
```

```
country STRING,
```

```
website STRING)
```

OPTIONS (


format='csv',

uris=['gs://bootcamp-data-analytics-public/ERP/companies.csv'],

skip_leading_rows = 1

);

Creación de american_users_raw:



En este caso, la creación de la tabla fue mucho más sencilla que las anteriores, ya que no fue necesario especificar el delimitador, definir manualmente los nombres y tipos de las columnas ni configurar opciones adicionales.

CREATE EXTERNAL TABLE IF NOT EXISTS `sprint3-analytics-gabriella.sprint3\_bronze.american\_users\_raw`


OPTIONS (

format='csv',

uris=['gs://bootcamp-data-analytics-public/CRM/american_users.csv']

);

Creación de european_users_raw:



Al igual que con la tabla anterior, para crear la tabla `european_users_raw`, la sintaxis fue más sencilla, ya que no fue necesario especificar delimitadores ni definir manualmente el esquema.

```
CREATE EXTERNAL TABLE IF NOT EXISTS `sprint3-analytics-gabriella.sprint3_bronze.european_users_raw`
```


```
OPTIONS (
```

```
  format='csv',
```

```
  uris=['gs://bootcamp-data-analytics-public/CRM/european_users.csv']
```


```
);
```

Creación de credit_cards_raw:



Al igual que con la tabla anterior, para crear la tabla de tarjetas de crédito, la sintaxis fue más sencilla, ya que no fue necesario especificar delimitadores ni definir manualmente el esquema.

```
CREATE EXTERNAL TABLE IF NOT EXISTS `sprint3-analytics-  
gabriella.sprint3_bronze.credit_cards_raw`  
  
OPTIONS (  
  
  format='csv',  
  
  uris=['gs://bootcamp-data-analytics-public/CRM/credit_cards.csv']  
  
);
```



Exercici 3: Càrrega de Dades Locals (Upload)

Falta el catàleg de **Productes**. Aquesta informació no és al Data Lake, utilitza el fitxer *products.csv* de l'sprint 2.

- » Carrega aquest fitxer manualment ("Upload") al dataset sprint3_bronze i crea la taula products_raw.
- » Observa que aquesta serà l'única **Taula Nativa** de moment.

Para crear la tabla products_raw de forma manual, fue necesario hacer clic en los tres puntos situados junto al dataset sprint3_bronze. A continuación, se realizó el upload del archivo y se indicó que se trataba de una tabla nativa.

Criar tabela

Origem

Create table from
Fazer upload

Selecionar arquivo *
N1-Ex_8_products.csv

Formato do arquivo
CSV

Destino

Projeto *
sprint3-analytics-gabriella

Conjunto de dados *
sprint3_bronze

Tabela *
products_raw

O tamanho máximo do nome é de 1.024 bytes UTF-8. Letras Unicode, marcas, números, conectores, traços e espaços são permitidos.

Tipo de tabela
Tabela nativa

Criar tabela Cancelar

Google Cloud sprint3-analytics-gabriella Pesquise (f) recursos, documentos, produtos e muito mais

Pesquise recursos do BigQuery

Mostrar apenas com estrela

Consultas

Notebooks

Telas de dados

Preparações de dados

Pipelines

Conexões

sprint3_bronze

american_users_raw

companies_raw

credit_cards_raw

european_users_raw

products_raw

transactions_raw

sprint3_gold

sprint3_silver

sprint3-analytics-gabriella / Datasets / sprint3_bronze

sprint3_bronze

Criar tabela

Chat

Visualização

Compartilhar

Copiar

Excluir

Visão geral

Detalhes

Insights

Tabelas

Gráficos

Modelos

Rotinas

Filtro Insira o nome ou o valor da propriedade

Código da tabela	Tipo	Horário da criação	Tempo de expiração	Marcador	
american_users_raw	Tabela	30 de set. de 2026, 17:51:57 UTC...	29 de nov. de 2026, 16:51:57 UTC...	Nenhum	☆
companies_raw	Tabela	30 de set. de 2026, 17:37:53 UTC...	29 de nov. de 2026, 16:37:53 UTC...	Nenhum	☆
credit_cards_raw	Tabela	30 de set. de 2026, 17:58:49 UTC...	29 de nov. de 2026, 16:58:49 UTC...	Nenhum	☆
european_users_raw	Tabela	30 de set. de 2026, 17:55:11 UTC...	29 de nov. de 2026, 16:55:11 UTC...	Nenhum	☆
products_raw	Tabela	1 de out. de 2026, 15:52:20 UTC+2	30 de nov. de 2026, 14:52:20 UTC...	Nenhum	☆
transactions_raw	Tabela	30 de set. de 2026, 17:36:50 UTC...	29 de nov. de 2026, 16:36:50 UTC...	Nenhum	☆

Exercici 4: Arquitectura i Rendiment. Materialització de Dades (Assistit per IA)

Escenari:

Les consultes sobre el Data Lake van lentes. Has de demostrar al teu mànager la diferència de rendiment entre treballar amb fitxers externs i treballar amb taules natives de BigQuery.

a) Materialització de Dades (Assistit per IA)

✿ Tasca:

Crea una nova taula anomenada sprint3_bronze.transactions_raw_native que sigui una còpia exacta de la teva taula externa transactions_raw.

Requisit de "AI-Pair Programming":

No escriguis el codi SQL manualment. Utilitza l'Assistent d'IA (Gemini) integrat a BigQuery (o el xat lateral) per generar la sentència.

👉 **El Teu Rol:** Ets el responsable de validar que el codi que et dona la IA és correcte abans d'executar-lo.


Prompt Sugerit:

"Write a SQL query to create a new table called transactions_raw_native in the sprint3_bronze dataset. It should contain all data from the transactions_raw table. Please use CREATE OR REPLACE TABLE so I don't get errors if I run it more than once."


👉 Entrega:

Una captura de pantalla on es vegi:


- » El prompt que vas escriure a la IA.



- » El codi SQL que la IA va generar.



- » El resultat de l'execució ("This statement created a new table...").




b) Auditoria de Custos

✿ Tasca:

Dissenyar una prova per comparar el cost de llegir una sola columna (ex: id) a la taula externa vs. la taula nativa. Utilitza els Bytes processats i els Bytes facturats per fer la comparació.

- » Quant "pesa" la consulta a transactions_raw?



- » Quant "pesa" la mateixa consulta a transactions_raw_native?

Google Cloud | sprint3-analytics-gabriella | Pesquise (/) recursos, documentos, produtos e muito mais

Consulta sem título | Executar | Salvar | Programação | Compartilhar

```

1 SELECT id FROM `sprint3-analytics-gabriella.sprint3_bronze.transactions_raw`;
2
3 SELECT id FROM `sprint3-analytics-gabriella.sprint3_bronze.transactions_raw_native`;

```

Consulta concluída
Usando cota de processamento sob demanda

Recente

- 16:38
- SELECT id FROM `sprint3-analytics-gabriella.sprint3\_bronze.transactions\_raw`
- SELECT id FROM `sprint3-analytics-gabriella.sprint3\_bronze.transactions\_raw\_native`
- 16:37

Resultados da...

Informações do job

Bytes processados	3,62 MB
Bytes faturados	10 MB
Slot em milissegundos	621
Prioridade de job	INTERACTIVE
Usar SQL legado	false
Tabela de destino	Tabela temporária
Rótulos	

👉 Entrega:

Captures del validador mostrant la diferència i una conclusió tècnica.

Los bytes procesados para la consulta sobre transactions_raw fueron de 12,61 MB y los bytes facturados de 13 MB, mientras que para la consulta sobre transactions_raw_native los bytes procesados fueron de 3,62 MB y los bytes facturados de 10 MB. Estos resultados muestran una diferencia entre ambas operaciones. La consulta sobre la tabla nativa redujo aproximadamente un 71,3% los bytes procesados y un 23,1% los bytes facturados respecto a la tabla externa. Además, el tiempo de ejecución también fue inferior en la tabla nativa. Por tanto, los datos en una tabla nativa de BigQuery puede reducir la cantidad de datos procesados y, en consecuencia, el volumen de bytes facturados por las consultas.

c) El perill del LIMIT

El LIMIT estalvia dades processades a BIGQUERY?

✿ Tasca:

Fes un **LIMIT 10** sobre la taula transactions_raw_native y la taula transactions_raw

✅ **Comprovació:** Mira el "Dry Run". Ha baixat el cost respecte a no posar LIMIT? Explica breument per què això és una trampa per a principiants.

El LIMIT limita el número de filas, pero no necesariamente reduce los datos que BigQuery necesita procesar. Además, en el caso de tablas externas, el Dry Run puede mostrar 0 bytes aunque la consulta procese datos, ya que el volumen de datos de la fuente externa no siempre puede determinarse antes de ejecutar la consulta.

The screenshot shows the Google Cloud BigQuery console interface. The browser tab is 'sprint3-analytics-gabriella'. The search bar contains 'Pesquise (/) recursos, documentos, produtos e muito mais'. The main area displays a SQL query in a dark-themed editor:

```
1 SELECT id
2 FROM `sprint3-analytics-gabriella.sprint3_bronze.transactions_raw`
3 LIMIT 10;
```

The status bar at the bottom indicates: 'Esta consulta vai processar 0 B quando executada.'

The screenshot shows the Google Cloud BigQuery console interface. The browser tab is 'sprint3-analytics-gabriella'. The search bar contains 'Pesquise (/) recursos, documentos, produtos e muito mais'. The main area displays a SQL query in a dark-themed editor:

```
1 SELECT id
2 FROM `sprint3-analytics-gabriella.sprint3_bronze.transactions_raw_native`
3 LIMIT 10;
```

The status bar at the bottom indicates: 'Esta consulta vai processar 3,62 MB quando executada.'


Exercici 5: Adaptació de Sintaxi (Reporting)

El teu cap vol saber quins van ser els **5 dies amb més ingressos de l'any 2021**.

Repte:

Probablement el camp timestamp és un STRING. Hauràs d'investigar funcions de BigQuery (SUBSTR, CAST, PARSE_TIMESTAMP) per filtrar l'any i agrupar per data correctament

Exploré dos funciones distintas para resolver esta pregunta. Para filtrar el año 2021 opté por utilizar EXTRACT, ya que me resultó más sencillo obtener únicamente los datos correspondientes a este año. Para convertir el campo TIMESTAMP en DATE utilicé CAST, eliminando así la información relativa a la hora. Para el resto del ejercicio seguí el mismo razonamiento que utilizaría en una consulta SQL tradicional: agrupar por fecha, calcular la suma de los ingresos, ordenar de forma descendente y limitar el resultado a los cinco primeros días.




Exercici 6: Consultes Complexes


Necessitem un informe que creui dades.

✂ Tasca:

Llista el nom, país i data de les transaccions realitzades per empreses que van fer operacions entre 100 i 200 euros en alguna d'aquestes dates: 29-04-2015, 20-07-2018 o 13-03-2024.

Para realizar el filtrado de las fechas, opté por utilizar la función CAST para convertir el campo TIMESTAMP en DATE y obtener únicamente la fecha de la operación. Para cumplir con el ejercicio, fue necesario realizar un JOIN con la tabla companies_raw y aplicar filtros adicionales sobre la fecha, el importe de la operación y su estado de aceptación.





Nivell 2: Neteja i Transformació (ELT)

Escenari:

Les dades brutes tenen problemes de qualitat (símbols de moneda, usuaris duplicats, dates incorrectes). Actua com a Data Engineer per netejar-ho tot.

Exercici 1: Neteja de Productes (Data Quality)

Crearem la capa neta ("Silver") per als productes. Tens la taula `sprint3-bronze.products_raw` carregada des del CSV. L'equip de Data Governance et demana crear una taula de productes neta a `sprint3-silver.products_clean` que compleixi aquestes regles de qualitat:

- » **Estandardització de Noms:** La columna original `id` és ambigua; reanomena-la a `product_id`. La columna `product_name` simplifica-la a `name`.
- » **Neteja d'IDs:** El camp `warehouse_id` té el format antic "WH-4". Elimina el prefix "WH-" i converteix el valor a número enter (INT64).
- » **Garantia de Preu:** Assegura't que `price` és un número (FLOAT64), sense símbols de moneda.
- » **Altres columnes:** Conserva el camp `weight` (pes) tal qual.

Para crear la tabla `products_clean` en el dataset Silver, utilicé `CREATE OR REPLACE TABLE`. Para eso, fue necesario revisar las columnas existentes en la tabla `products_raw` y renombrarlas cuando era necesario, por ejemplo, de `id` a `product_id` y de `product_name` a `name`.

Para realizar la limpieza de la columna `warehouse_id`, me resultó más sencillo utilizar la función `REPLACE`. De esta manera, eliminé el prefijo `WH-` y posteriormente convertí el valor de `STRING` a `INT64`.

La columna `price` ya estaba clasificada como `FLOAT64`, por lo que no fue necesario realizar ninguna modificación. Las demás columnas también se conservaron sin transformaciones.

```
CREATE OR REPLACE TABLE `sprint3-analytics-  
gabriella.sprint3_silver.products_clean` AS
```

```
SELECT
```

```
id AS product_id,
```

```
product_name AS name,
```

```
price, --price ya está como FLOAT
```

```
colour,
```

```
weight,
```

```
CAST(REPLACE(warehouse_id,'WH-','') AS INT64) AS warehouse_id,
```


```
category,
```

```
brand,
```

```
cost,
```

```
launch_date
```

```
FROM `sprint3-analytics-gabriella.sprint3_bronze.products_raw`
```



Exercici 2: Creació de Transaccions Netes (Capa Silver)

Escenari:

La taula transactions_raw (Bronze) és insegura: l'import (amount) podria tenir lletres, les coordenades podrien fallar i la data és un text difícil de filtrar. Crearem la taula definitiva sprint3_silver.transactions_clean que garanteixi el següent.

- » **Estandardització de Noms:** La columna original id és ambigua; reanomena-la a transaction_id.
- » **Robustesa en Imports:** Utilitza SAFE_CAST al camp amount. Si falla, substitueix-lo per 0 (usant IFNULL).
- » **Dates Reals:** Converteix el camp timestamp (que és STRING) a tipus TIMESTAMP real.
- » **Coordenades:** Assegura que lat i longitude siguin FLOAT64 (utilitza SAFE_CAST per seguretat).
- » **Desglose de Productos:** Transforma la cadena de texto product_ids en un **ARRAY de enteros**.
 - *Input:* "1, 2, 3" (String)
 - *Output:* [1, 2, 3] (Array/Lista de enteros)
- » **Resta de camps:** Mantén-los igual.

Así como en el ejercicio anterior, creé la nueva tabla utilizando CREATE OR REPLACE TABLE y realicé todas las transformaciones necesarias, como los ajustes en los nombres de las columnas y la conversión de las variables mediante SAFE_CAST.

Para crear el ARRAY de product_ids, fue necesario realizar varias etapas. Primero utilicé SPLIT para separar los diferentes identificadores. Después, utilicé UNNEST para descomponer los elementos del ARRAY generado por SPLIT y poder trabajar con cada valor individualmente. A continuación, utilicé TRIM para eliminar los espacios y SAFE_CAST para convertir cada elemento a INT64. Finalmente, agrupé nuevamente los valores en un ARRAY de enteros.

```
CREATE OR REPLACE TABLE `sprint3-analytics-  
gabriella.sprint3_silver.transactions_clean` AS
```

```
SELECT
```

```
id AS transaction_id,
```

```
card_id,
```

```

business_id,

SAFE_CAST(timestamp AS timestamp) AS timestamp,

IFNULL(SAFE_CAST(amount AS FLOAT64), 0) AS amount,

declined,

ARRAY(

  SELECT SAFE_CAST(TRIM(product_id) AS INT64)

  FROM UNNEST(SPLIT(product_ids, ',')) AS product_id

) AS product_ids,


user_id,

SAFE_CAST(lat AS FLOAT64) AS lat,

SAFE_CAST(longitude AS FLOAT64) AS longitude

FROM `sprint3-analytics-gabriella.sprint3_bronze.transactions_raw_native`;

```



Exercici 3: Unificació d'Usuaris (UNION)

Tenim els usuaris fragmentats per regió.

Tasca:

Crea la taula `sprint3_silver.users_combined`. Utilitza `UNION ALL` per unificar els usuaris dels EUA i Europa en una única llista mestra. Afegeix una columna calculada `origin` per saber d'on venen.

- » **Estandarització de Noms:** La columna original id és ambigua; reanomena-la a user_id.

Para crear la tabla users_combined, utilicé CREATE OR REPLACE TABLE y unifique las tablas european_users_raw y american_users_raw mediante UNION ALL.

Renombré la columna id como user_id. También añadí una nueva columna llamada origin, asignando el valor europe a los usuarios procedentes de la tabla europea y america a los usuarios procedentes de la tabla americana.

```
CREATE OR REPLACE TABLE `sprint3-analytics-
gabriella.sprint3_silver.users_combined` AS
```

```
SELECT
```

```
  id AS user_id, name, surname, phone, email, birth_date, country, city,
postal_code, address, 'europe' AS origin
```

```
FROM `sprint3-analytics-gabriella.sprint3_bronze.european_users_raw`
```


```
UNION ALL
```

```
SELECT
```

```
  id AS user_id, name, surname, phone, email, birth_date, country, city,
postal_code, address, 'america' AS origin
```

```
FROM
```

```
`sprint3-analytics-gabriella.sprint3_bronze.american_users_raw`;
```



Exercici 4: Materialització de Companyies i Targetes de Crèdit

Escenari:

Per completar el model de dades a la capa Silver, ens falten dues dimensions clau que actualment depenen de fitxers CSV externs: **Companyies** i **Targetes de Crèdit**. No podem dependre de fitxers solts per a l'anàlisi final. Hem d'importar aquestes dades a taules natives (Silver) i aprofitar per corregir formats.

✿ Tasques:

- » 1. Crea la taula `sprint3_silver.companies_clean`. Copia les dades tal qual, però assegura't que sigui una taula nativa de BigQuery (no una vista externa).
- » 2. Crea la taula `sprint3_silver.credit_cards_clean`. Copia les dades tal qual, però assegura't que sigui una taula nativa de BigQuery (no una vista externa).

Si cal, reanomenar l'id segons correspongui.

Para completar la capa Silver, materialicé las tablas `companies_raw` y `credit_cards_raw` como tablas nativas de BigQuery mediante `CREATE OR REPLACE TABLE`. En ambos casos, mantuve los campos originales sin realizar transformaciones, ya que el ejercicio únicamente requería importar los datos desde las tablas externas y disponer de ellos como tablas nativas dentro de la capa Silver. En el caso de `credit_cards_clean`, renombré la columna `id` como `credit_card_id` para hacer más explícita su función como identificador de la tarjeta.

```
CREATE OR REPLACE TABLE `sprint3-analytics-gabriella.sprint3_silver.companies_clean` AS
```

```
SELECT
```

```
  company_id, company_name, phone, email, country, website
```

```
FROM
```

```
`sprint3-analytics-gabriella.sprint3_bronze.companies_raw`;
```

```
CREATE OR REPLACE TABLE `sprint3-analytics-gabriella.sprint3_silver.credit_cards_clean` AS
```


```
SELECT
```

```
  id AS credit_card_id,
```

user_id, iban, pan, pin, cvv, track1, track2, expiring_date

FROM

```
`sprint3-analytics-gabriella.sprint3_bronze.credit_cards_raw`;
```



Nivell 3: Presentació de Dades i Creació de Vistes

Escenari:

Al nivell anterior vas actuar com a Data Engineer netejant les dades (_clean). Ara toca posar-se el barret d'Analista de Negoci. El problema actual és que les taules estan separades i algunes tenen formats difícils d'explotar (com la llista de productes comprimida en una sola cel·la). En aquest nivell crearàs **Vistes** per facilitar l'accés a la informació i generaràs informes finals.

Objectius:

- » Crear Vistes (CREATE VIEW) per encapsular lògica de negoci complexa.
- » Resoldre el repte de dades agrupades en strings (SPLIT + UNNEST).
- » Exportar resultats per a tercers (Reverse ETL).

Exercici 1: La Vista de Màrqueting (Lògica de Negoci)

Màrqueting necessita segmentar els clients corporatius, però no saben fer JOINS. La teva tasca és deixar-los la informació preparada.


Tasca:

Crea una vista anomenada `sprint3_gold.v_marketing_kpis` que mostri la següent informació per a cada companyia:

- » **Nom de la companyia, Telèfon i País** (origen: companies_clean).
- » **Mitjana de compra** (AVG(amount) de transactions_clean).
- » **Classificació de Client (Lògica):**
 - Crea una columna calculada anomenada client_tier.
 - Si la mitjana de compra és superior a **260€**, etiqueta com a **"Premium"**.
 - Si és igual o inferior, etiqueta com a **"Standard"**.

Para crear la vista, el proceso fue bastante sencillo, ya que la sintaxis es muy similar a MySQL. Utilicé CREATE VIEW y seleccioné los datos necesarios de las tablas correspondientes. Para obtener la información de las compañías y sus transacciones, realicé un JOIN entre companies_clean y transactions_clean. Después, utilicé AVG junto con GROUP BY para calcular la media de compra de cada compañía. Para crear la columna client_tier, utilicé CASE y clasifiqué las compañías según la media obtenida.

```
CREATE VIEW `sprint3-analytics-gabriella.sprint3_gold.v_marketing_kpis` AS
SELECT company_id, company_name, phone, country, AVG(t.amount) AS
media_transacciones,
CASE WHEN AVG(t.amount) > 260 THEN 'Premium'
ELSE 'Standard'
END AS client_tier
FROM `sprint3-analytics-gabriella.sprint3_silver.companies_clean` c
JOIN `sprint3-analytics-gabriella.sprint3_silver.transactions_clean` t ON
c.company_id = t.business_id
GROUP BY company_id, company_name, phone, country;
```



👉 Entrega:


Realitza una consulta SELECT * sobre la teva nova vista, ordenant els resultats perquè apareguin primer els clients "Premium" i, dins d'aquests, els que tinguin major mitjana de compra.

Por último, realicé un SELECT sobre la vista creada y ordené los resultados por client_tier y por la media de compra, de acuerdo con lo solicitado.

SELECT *

FROM sprint3-analytics-gabriella.sprint3_gold.v_marketing_kpis

ORDER BY client_tier ASC, media_transacciones DESC;



Exercici 2: Rànquing de Productes (La Potència dels Arrays)

Escenari de Negoci:

L'equip de vendes vol optimitzar el catàleg. Necessiten un informe a la capa Gold que mostri el rendiment real de cada producte. Gràcies a la teva bona enginyeria a la capa Silver, la taula transactions_clean ja té els IDs de producte perfectament organitzats en una llista (Array). Ara toca explotar aquesta estructura.

Objectiu:

Crea la taula sprint3_gold.product_sales_ranking que contingui l'inventari complet de productes i quantes vegades s'ha venut cadascun.

Requisits de l'Informe:

- » **Detall del Producte:** Ha d'incloure product_id, name, price i color (vénen de la taula products_clean).
- » **Mètrica de Negoci:** Una columna nova total_sold que compti quantes vegades apareix aquest producte a les transaccions.
- » **Integritat:** Han d'aparèixer tots els productes, fins i tot els que tenen 0 vendes (potser cal descatalogar-los).

Pista Tècnica:

- » A transactions_clean, els productes estan "encapsulats" dins d'un Array per cada transacció.
- » Primer necessitaràs "aplanar" la taula de transaccions usant UNNEST(product_ids) per poder comptar els productes individualment.
- » Després, fes un encreuament (LEFT JOIN) començant per la taula de productes per no perdre aquells que no s'han venut mai.

Para crear la tabla de ventas, fue necesario utilizar UNNEST para descomponer el ARRAY de product_ids y obtener los productos de cada transacción de forma individual. A partir de estos datos, realicé un LEFT JOIN con la tabla products_clean para mantener todos los productos, incluso aquellos que no tuvieron ninguna venta. Finalmente, utilicé COUNT para calcular el total de ventas de cada producto y creé la tabla mediante CREATE OR REPLACE TABLE.

```
CREATE OR REPLACE TABLE `sprint3-analytics-  
gabriella.sprint3_gold.product_sales_ranking` AS
```

```
SELECT ps.product_id, ps.name, ps.price, ps.colour, COUNT(p.product_id) AS  
total_sold
```

```
FROM `sprint3-analytics-gabriella.sprint3_silver.products_clean` ps
```


```
LEFT JOIN (SELECT product_id
```

```
FROM `sprint3-analytics-gabriella.sprint3_silver.transactions_clean`

CROSS JOIN UNNEST(product_ids) AS product_id ) AS p ON ps.product_id =
p.product_id

GROUP BY ps.product_id, ps.name, ps.price, ps.colour

ORDER BY total_sold DESC;
```



Exercici 3: Exportació de Resultats

El teu mànager no té accés a BigQuery i vol el llistat de "Top Productes" en un Excel per a una reunió.

Tasca:

Exporta les dades de la taula `product_sales_ranking` a **Google Sheets** o baixa l'arxiu **CSV** localment.

Entrega:

Una captura de pantalla on es vegi l'arxiu obert (Excel/Sheets) amb les dades correctament formatades.

Para realizar la exportación, ejecuté una consulta sobre `product_sales_ranking` y seleccioné la opción **“Guardar resultados”**. Entre las opciones disponibles, elegí descargar los resultados en formato CSV y posteriormente abrir el archivo en Google Sheets.

Google Cloud sprint3-analytics-gabriella

Pesquise recursos do BigQuery

Consulta sem título

```
1 SELECT *
2 FROM `sprint3-analytics-gabriella.sprint3_gold.product_sales_ranking`;
```

Consulta concluída

Usando cota de processamento sob demanda

Recente

Resultados da...

Linhas

Linha	product_id	name	price
1	52	riverlands the duel	
2	29	Tully maester Tully	
3	21	duel Direwolf	
4	16	the duel warden	

Resultados por página: 50 1 - 50 de 100

Copiar para a área de transferência Até 1 MB

Google Drive

CSV Até 1 GB

JSONL (delimitado por nova linha) Até 1 GB

Google Planilhas Até 10 MB

Download local

CSV Até 10 MB

JSON Até 10 MB

Google Cloud

Cloud Storage

Tabela do BigQuery

drive.google.com/file/d/16CT3eLLXElncsWoQ8cs5VwptQ9MqIdZj/view

bq-results-20261007-161737-1791389889781.csv

Arquivo Acessar Inserir Ferramentas Ajuda

Comentário

	A	B	C	D	E
	product_id	name	price	colour	total_sold
1	52	riverlands the duel	31.52	#727272	2654
2	29	Tully maester Tully	167.2	#111111	2635
3	21	duel Direwolf	96.9	#62e2e2	2609
4	16	the duel warden	180.91	#666666	2608
5	66	mustafar jinn	2.12	#545454	2601
6	87	sith Jade	96.26	#a2e2e2	2588
7	48	rock Renly in	21.53	#9e9e9e	2597
8	33	duel warden	127.09	#191919	2597
9	23	riverlands north	169.96	#545454	2593
10	68	Stark Karstark	167.37	#333333	2589
11	88	Stannis warden south	167.15	#515151	2587
12	28	chewbacca mustafar	127.44	#e2e2e2	2584
13	4	warden south duel	71.89	#111111	2584
14	73	Dome bastard	114.09	#848484	2584
15	31	Lannister	85.02	#3f3f3f	2580
16	34	of north	128.48	#919191	2580
17	38	evok sith	55.43	#666666	2578
18	36	Lannister	96.22	#a5a5a5	2575
19	61	Winterfell Lannister	28.01	#848484	2575
20	54	dooku solo	13.14	#a5a5a5	2575
21	24	south duel tourney	48.99	#aaaaaa	2574
22	11	Karstark Dome	49.7	#141414	2573
23					